



MACHINE LEARNING I - CC2008

SVM para Classificação Multiclasse

Estudo do impacto da decomposição binária e proposta de uma variante baseada em Error-Correcting Output Codes

GRUPO PL2_G8

Bernardo Soeiro - up202406233

Rodrigo Dias - up202407281

maio 2026

Sumário Executivo



Objectivo

Estudar o SVM em problemas multiclasse, identificar limitações estruturais das estratégias clássicas e propor uma variante mais robusta.



Abordagem

Implementação de raiz do SVM com SMO. Comparação OvR vs OvO em 11 datasets (Fase 1); proposta de variante ECOC com correcção de erros (Fase 2).



Resultado

O ECOC ganha à melhor baseline em Macro F1 com destaque para datasets desequilibrados: Lymph +7.7pp, Grub-Damage +5.3pp.

PRINCIPAL CONCLUSÃO

A redundância via codificação ECOC mitiga falhas estruturais do OvR/OvO em datasets desequilibrados, mas não substitui separabilidade ausente — TAE permanece intrinsecamente difícil.

Algoritmo: Support Vector Machine

Maximização da margem entre classes via problema de otimização quadrático

Formulação

Problema primal — margem máxima com slack:

$$\begin{aligned} \min \quad & \frac{1}{2} \|w\|^2 + C \cdot \sum \xi_i \\ \text{s.a.} \quad & y_i(w \cdot x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \end{aligned}$$


Dual (Lagrange):

$$\begin{aligned} \max \quad & \sum \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j K(x_i, x_j) \\ & 0 \leq \alpha_i \leq C, \quad \sum \alpha_i y_i = 0 \end{aligned}$$

Implementação

- SMO (Sequential Minimal Optimization) — actualiza pares (α_i, α_j) iterativamente
- Kernels: Linear, Polinomial, RBF ($\gamma=0.1$)
- Implementação de raiz (NumPy); base em rushter/MLAlgorithms

Intuição geométrica



Desafio: SVM é intrinsecamente binário

Para $k > 2$ classes, é necessário decompor o problema em múltiplos sub-problemas binários

One-vs-Rest (OvR)

Treina k classificadores: classe i vs. todas as restantes

k classificadores binários

Limitação:

desequilíbrio inerente — 1 classe contra $k-1$; escalas de decisão entre classificadores não-comparáveis.

One-vs-One (OvO)

Treina um classificador por cada par de classes; previsão por votação

$k(k-1)/2$ classificadores binários

Limitação:

crescimento quadrático com k ; regiões de ambiguidade (votos empatados); classes raras geram pares com poucos exemplos.



HIPÓTESE INICIAL

Em ambas as estratégias o desempenho degrada-se à medida que k cresce, especialmente em datasets com classes pouco separáveis. O OvO deverá ser globalmente mais robusto que o OvR para k grande — mas pode sofrer em datasets com classes muito pequenas.

Proposta: ECOC-SVM

Error-Correcting Output Codes — redundância deliberada nos classificadores binários

MOTIVAÇÃO

OvR e OvO não têm mecanismo de correção de erros: se um classificador binário erra, o erro propaga-se directamente para a previsão final.

1 Codificação

Cada classe é representada por um codeword binário de comprimento L numa matriz $M \in \{-1, +1\}^{(k \times L)}$. Cada coluna define um problema binário.

2 Treino

Treina L SVMs binários (RBF, $C=1.0$, $\gamma=0.1$), um por coluna, em paralelo (joblib). Usa $L = \max(15, 10k)$.

3 Descodificação

Para x , obtém-se $f(x) \in \{-1, +1\}^L$; classe = $\arg \min_i d_H(M_i, f(x))$. Tolerar $\lfloor (d_{\min}-1)/2 \rfloor$ erros.

OvR: $L=k$, $d_{\min}=2$, 0 erros tolerados • OvO: $L=k(k-1)/2$, $d_{\min}=\lfloor Lk/2 \rfloor$ • **ECOC**: $L=10k$, $d_{\min} \approx L/3$, $\approx L/6$ erros tolerados

Estudo Empírico — Datasets

11 datasets do Grupo 3, com diversidade em k , n , p , imbalance ratio e tamanho mínimo de classe

Dataset	k	n	p	IR	min cls
Iris	3	150	4	1.0	50
Wine	3	178	13	1.5	48
TAE	3	151	5	1.1	49
Hayes-Roth	3	160	4	1.7	31
Balance-Scale	3	400	4	5.9	32
Lymph	4	148	18	40.5	2
Vehicle	4	400	18	1.0	94
Grub-Damage	4	155	8	2.2	27
Zoo	7	101	17	10.3	4
Glass	6	214	9	8.4	9
Ecoli	8	336	7	71.5	2

Imbalance Ratio (IR)

Razão classe majoritária / minoritária. IR elevado penaliza OvR (1-vs-resto fica muito desequilibrado) e OvO (pares com classe rara têm poucos exemplos).

Tamanho mínimo de classe

Limita o que se consegue aprender numa classe. Zoo (4 instâncias) e Lymph/Ecoli (2 instâncias) são casos críticos para qualquer estratégia.

Pré-processamento

- LabelEncoder para features categóricas
- Imputação por mediana para missing values
- Z-score por feature
- Sub-amostragem estratificada para $n > 400$

Metodologia Experimental

Mesmo protocolo nas Fases 1 e 2 para comparação justa entre estratégias



Validação

- Stratified 5-Fold Cross-Validation
- Preserva proporção de classes em cada fold — crítico para classes raras (Zoo: 4 instâncias)
- Trade-off bias/variance equilibrado



Métricas

- Accuracy — proporção de acertos
- Macro F1 — média não-pesada por classe; penaliza falhas em classes minoritárias
- Reportadas como média $\pm$ desvio em 5 folds



Hiperparâmetros

- Kernel RBF, $\gamma = 0.1$ (calibrado para dados z-score)
- $C = 1.0$ (regularização default)
- SMO: $\text{tol} = 1e-2$, $\text{max_iter} = 50$




ECOC

- $L = \max(15, 10 \cdot k)$ classificadores
- Matriz aleatória densa, escolhida entre 20 candidatas pelo maior $d_{\min}$
- Decodificação por distância de Hamming

Resultados — Fase 1: OvR vs OvO

Macro F1 (média 5-fold) por dataset — ordenado por k crescente



OBSERVAÇÕES


- Boa separabilidade → ambas as estratégias funcionam (Iris, Wine).
- k grande ≠ OvO vence: Zoo (k=7) e Ecoli (k=8) mostram OvR superior.
- TAE e Grub-Damage estagnam abaixo de 50% Acc — separabilidade intrínseca baixa.
- Lymph: Acc≈80% mas F1≈0.53 — classes minoritárias ignoradas.



HIPÓTESE PARCIALMENTE REFUTADA — o factor determinante não é k mas sim separabilidade intrínseca + imbalance ratio + tamanho mínimo de classe.

Resultados — Fase 2: ECOC vs Baselines

Macro F1 (média 5-fold) — comparação das 3 estratégias



✓ GANHOS PRINCIPAIS

Lymph F1 +0.077
Grub-Damage F1 +0.053
TAE Acc +2.5pp
Bal.-Scale Acc +3.3pp
Iris Acc +0.7pp

✗ REGRESSÕES

Zoo F1 - 0.040
Hayes-Roth Acc - 1.8pp
Vehicle F1 - 0.012

Zoo: $n=101$ com $L=70 \rightarrow$ classificadores binários treinados com classes a 1–2 instâncias.

WIN / TIE / LOSS (Macro F1, tol = 0.005) ECOC vs OvR: 8 / 1 / 2 • ECOC vs OvO: 8 / 2 / 1

Síntese — Win / Tie / Loss

Comparação par-a-par ECOC vs. baselines em 11 datasets · tolerância: 0.005 em Acc e Macro F1

ECOC vs. OvR

6

WINS

2

TIES

3

LOSSES

em Macro F1 · 11 datasets

ECOC vs. OvO

8

WINS

1

TIES

2

LOSSES

em Macro F1 · 11 datasets

Discriminação por dataset (Macro F1)

ECOC vence

Lymph · Grub-Damage · Iris · Glass · Ecoli · Wine ·
Hayes-Roth (vs OvR)

Empate

Vehicle (vs OvR e OvO) · Hayes-Roth (vs OvO) ·
separabilidade já saturada - ECOC não diverge.


ECOC perde

Zoo (vs OvR e OvO) · TAE · Balance-Scale

Saldo claramente favorável ao ECOC em ambas as comparações; perdas concentradas em Zoo (dataset pequeno).

Análise: quando compensa pagar redundância?

Custo computacional vs. ganho em Macro F1 — três regimes distintos



ECOC é a escolha preferível

datasets com imbalance ratio elevado E instâncias suficientes para $L=10k$ classificadores informativos (Lymph, Grub-Damage, Balance-Scale).

OvR mantém vantagem

datasets muito pequenos com classes raras — L grande dilui o sinal por classificador (Zoo: 101 inst., 4-inst. na classe rara).

Nenhuma estratégia resolve

datasets com baixa separabilidade intrínseca — TAE: redundância não substitui informação ausente nas features.



ECOC custa ~10× mais classificadores que OvR (linear em k), mas converte esse custo em ganho real onde os baselines falham — sobretudo em Macro F1 de datasets desequilibrados.

Conclusões & Trabalho Futuro

CONCLUSÕES

Hipótese inicial parcialmente refutada

O factor crítico não é k , mas separabilidade + IR.

ECOC valida-se em desequilíbrio

Ganhos expressivos em Lymph (+7.7pp F1) e Grub-Damage (+5.3pp F1) pela diversificação das partições binárias.

Limite estrutural do ECOC

Regride em Zoo ($n=101$, $L=70$) — a redundância só ajuda quando os classificadores base são informativos.

TAE: redundância não compensa features pouco informativas

Separabilidade intrínseca é o tecto.

TRABALHO FUTURO

1

Grid search por dataset

Tuning de C e γ poderá isolar melhor o efeito da estratégia multiclasse.

2

L adaptativo

Reduzir L para datasets pequenos (e.g. $n/k < 15$) para evitar regressões tipo Zoo.

3

Descodificação por margem

Substituir Hamming por distância contínua baseada nos valores de decisão.

4

Outros kernels

Linear/polinomial em datasets de alta dimensão (Vehicle, Lymph).